PROSPERAI HEALTH TECH • DOCUMENTO DE ARQUITECTURA Y OPERACIÓN

ProsperAI Clinic: Documentación Integral

Manual maestro de arquitectura, flujos clínicos, economía unitaria y puesta en marcha para directores y desarrolladores.

Versión: 2.4.0 (Producción)
Estado: Aprobado Clínico
Ámbito: EHR & IA de Voz

Resumen Ejecutivo: ProsperAI Clinic es un sistema operativo clínico de atención telefónica y rescate de citas impulsado por Inteligencia Artificial y WebRTC. A través de *Clara* (recepcionista de voz en tiempo real), el sistema atiende llamadas entrantes 24/7, verifica seguros al instante y recupera cancelaciones en menos de 60 segundos conectándose con el archivo de lista de espera médica.

1 ¿Qué Problema Resuelve en la Práctica Médica?

1. No-Shows Millonarios

-30% PÉRDIDAS

Del 15% al 30% de los turnos se cancelan a última hora o sufren inasistencia, costando entre **$150 y $300 USD por hueco** sin capacidad humana de rescate.

2. Saturación en Recepción

4-6 H/DÍA

El personal administrativo gasta más de 5 horas contestando preguntas idénticas de horarios y copagos, provocando 10 a 15 min de espera y fuga de pacientes.

3. Fricción en Coberturas

< 300 MS

Los portales legacy dificultan calcular el copago exacto. ProsperAI valida la aseguradora de manera síncrona en milisegundos mediante el conector EHR.

2 Arquitectura Global: La Analogía del Hospital

Para comprender el flujo sin requerir conocimiento técnico avanzado, cada componente equivale a un rol clave en un centro de salud:

Paciente (Voz en Vivo)
Llama por teléfono convencional o accede vía micrófono desde el portal web vía canal WebRTC de baja latencia.

Clara (Recepcionista - agent.py)
Oídos (Deepgram), Reflejos (Silero VAD), Cerebro (GPT-4o) y Cuerdas Vocales humanas (Cartesia TTS).

El Gestor de Citas (EHR API)
Valida agendas médicas de los facultativos, audita pólizas de seguros y dispara llamadas de recuperación.

Archivo y Cuadro de Mando (Supabase & Dashboard)
Persistencia en PostgreSQL bajo reglas RLS, historial de llamadas, telemetría y lista de espera por gravedad médica.

< 750 ms	$0.28 USD	< 60 seg
LATENCIA CONVERSACIONAL	COSTE PROMEDIO LLAMADA	REASIGNACIÓN DE TURNO

3 Los 4 Pilares Fundamentales del Sistema

La solución desacopla la percepción en tiempo real, el razonamiento clínico, la capa de persistencia y la monitorización visual del hospital.

Pilar 1: Clara (Agente de Voz)

AGENT.PY

Interacción oral con respuesta fluida y capacidad de corte natural:

- **Silero VAD (Reflejos):** Detecta pausas e interrupciones del paciente sin latencia perceptible.
- **Deepgram Nova-2 (Oídos):** STT médico veloz (<150ms) con reconocimiento de acentos.
- **GPT-4o-mini (Cerebro):** Contextualiza dolencias, filtra emergencias y extrae entidades.
- **Cartesia Sonic-3 (Voz):** Síntesis ultra-humana con emoción y pronunciación adaptativa.
- **LiveKit Cloud (Red WebRTC):** Puente de audio bidireccional estable.

Pilar 2: Cerebro Clínico (EHR API)

EHR_API.PY

Servicios backend construidos sobre FastAPI de alto rendimiento:

- **Disponibilidad Médica:** Consulta de turnos libres filtrados por especialidad.
- **Verificador de Cobertura:** Consulta reglas de copago con aseguradoras (Aetna, BlueCross).
- **Confirmación Atómica:** Reserva de turnos y emisión de código único de cita.
- **Trigger de Cancelaciones:** Detección de turnos desiertos y disparo de llamadas.
- **Telemetría Viva:** Monitorización en tiempo real de costes y latencia por llamada.

Pilar 3: Base de Datos Inteligente

SUPABASE POSTGRESQL

Almacenamiento relacional seguro con políticas de privacidad RLS:

- `patients`: Registros personales, póliza de cobertura y contacto.
- `waitlist`: Cola priorizada según cuadro clínico (ej: Prioridad 1 agudo vs. chequeo preventivo).
- `calls`: Auditoría forense de duración, audio, transcripción, coste y éxito operativo.
- **Cumplimiento de Privacidad:** Arquitectura alineada a estándares HIPAA y encriptación en reposo.

Pilar 4: Torre de Control

CLINIC-DASHBOARD

Interfaz administrativa en Next.js 16, React 19 y Tailwind CSS:

- **Llamada de Prueba WebRTC:** Botón *Start Test Call* para interactuar con Clara en directo desde el navegador.
- **Avatar de Estados en Vivo:** Escuchando, Pensando, Consultando EHR y Hablando.
- **Simulador de Cancelación:** Permite disparar el protocolo de rescate con un clic.
- **Métricas Operacionales:** Comparativa de costes IA vs. operador físico y tiempos de respuesta.

Pila Tecnológica Consolidada:

`Python 3.11` `FastAPI` `LiveKit Agents SDK` `Deepgram Nova-2` `Cartesia Sonic-3` `OpenAI GPT-4o-mini` `Supabase (PostgreSQL)` `Next.js 16 / React 19` `Tailwind CSS`

4 Diagramas y Flujos Operativos (Patient Journeys)

Representación paso a paso de los dos recorridos críticos: cita programada entrante y rescate proactivo por inasistencia.

Flujo A: Llamada Entrante (Inbound Patient Booking)

CANAL WEBRTC / PSTN

Paso 1: Apertura & Detección — `Silero VAD + Deepgram`

El paciente solicita atención en lenguaje natural ("Quiero ver a un médico general"). El agente transcribe el stream de audio en <150ms.

Paso 2: Consulta Síncrona al EHR — `GET /slots/available`

Clara consulta vacantes activas y ofrece a la Dra. Sarah Adams para el jueves a las 10:00 AM con voz fluida y timbre empático.

Paso 3: Verificación de Aseguradora — `POST /insurance/verify`

El paciente entrega su ID de seguro (Aetna). La API valida la póliza activa y confirma copago exacto de $25.00 en recepción.

Paso 4: Reserva & Código Único — `POST /slots/book`

Se genera el identificador `CONF-A18B3C`, se emite confirmación por voz y se alimenta la telemetría en el Dashboard.

Flujo B: Recuperación Proactiva de Cancelaciones (Outbound Recovery)

AUTÓNOMO EN < 60 SEG

1. Liberación de Agenda — `Evento de Cancelación`

Un paciente cancela cita de las 3:00 PM. El backend detecta la vacante de inmediato y bloquea la ranura temporal.

2. Búsqueda en Lista de Espera — `SELECT FROM waitlist`

El sistema selecciona al paciente con máxima prioridad clínica (ej. dolor agudo preferencial sobre chequeo preventivo).

3. Llamada Saliente Inmediata — `Clara Outbound Agent`

Clara llama a María García: *"Hola María, se ha liberado un hueco hoy a las 3:00 PM con tu médico. ¿Deseas ocuparlo?"*.

4. Reasignación & Ahorro Directo — `Slot Salvado ($200 USD)`

María confirma y el turno queda reasignado al instante. Si rechaza, el motor llama automáticamente al segundo candidato de la lista.

5 Catálogo de Endpoints y Servicios del EHR

La API REST de ProsperAI conecta la recepcionista artificial con las funciones centrales del software de la clínica.

ENDPOINT & MÉTODO	CONSUMIDOR	FUNCIÓN EN EL SISTEMA	RESPUESTA / PAYLOAD
GET `/slots/available`	CLARA (VOZ)	Devuelve facultativos y turnos disponibles filtrados por especialidad requerida.	`[{"dr": "Adams", "time": "10:00"}]`
POST `/insurance/verify`	CLARA (VOZ)	Comprueba validez del seguro del paciente y determina el copago exacto.	`{"eligible": true, "copay": 25.0}`
POST `/slots/book`	CLARA (VOZ)	Reserva el horario en firme en la base de datos y emite localizador médico.	`{"status": "confirmed", "code": "CONF-92"}`
POST `/cancellations/trigger-recovery`	DASHBOARD	Simula o tramita cancelación y activa el discador saliente de lista de espera.	`{"recovered": true, "slot": "15:00"}`
GET `/telemetry/live-calls`	DASHBOARD	Retorna historial de llamadas con duración, transcripción, latencia y costes.	`{"calls": [{"cost_usd": 0.28}]}`

6 Seguridad de Datos y Cumplimiento Médico

Protección RLS (Row Level Security) POSTGRESQL

Cada registro en las tablas de pacientes cuenta con políticas de acceso granular para evitar lectura cruzada entre diferentes organizaciones médicas o roles no autorizados.

Trazabilidad de Auditoría AUDIT TRAIL

Todas las llamadas almacenan su token de sesión, identificación de llamada saliente, eventos de transcripción y resultado clínico para auditorías médicas.

Tratamiento Ético y Redirección a Urgencias:
El prompt del agente Clara implementa una barrera de seguridad de primer nivel: ante expresiones como *"dolor en el pecho"*, *"dificultad respiratoria severa"* o pérdida de conocimiento, el sistema interrumpe el agendamiento y redirige inmediatamente al paciente a la línea 911 / servicios de urgencias físicos.

7 Métricas Económicas y Retorno de Inversión (Unit Economics)

Comparación exhaustiva de los costes operativos entre un modelo tradicional con personal en recepción y el agente autónomo ProsperAI Clinic.

DIMENSIÓN OPERATIVA	RECEPCIÓN TRADICIONAL	PROSPERAI CLINIC (CLARA)	IMPACTO FINANCIERO
Coste por llamada (3 min)	**$2.25 USD** (Salario $18-22/h + cargas)	**$0.28 USD** (STT + LLM + TTS + LiveKit)	-87.5% DE AHORRO
Disponibilidad de atención	8 horas/día (L-V) Llamadas perdidas de noche/fin de semana	**24/7/365** Atención síncrona sin colas	100% DE COBERTURA
Tiempo de espera en línea	5 a 15 minutos en picos	**0 segundos**	FRICCIÓN CERO
Recuperación de cancelaciones	Manual e infrecuente	**Autónoma en < 60 seg**	+$150 A $300 / TURNO
Pérdida anual por turnos vacíos	$120,000 - $180,000 USD	Reducción superior al 60%	+$75K-$110K RECUPERADOS

Desglose de Costes Directos en una Llamada de 2 Minutos

STT (TRANSCRIPCIÓN)
~$0.015
Deepgram Nova-2 (~$0.0043/min)

LLM (RAZONAMIENTO)
~$0.025
OpenAI GPT-4o-mini (Tokens)

TTS (VOZ EN VIVO)
~$0.050
Cartesia Sonic-3 (Caracteres)

RED WEBRTC
~$0.010
LiveKit Cloud Data Egress

Conclusión Financiera:
El modelo demuestra rentabilidad inmediata. Con un coste total de **$0.10 a $0.28 USD por interacción completa**, una clínica promedio que rescata solo tres turnos cancelados a la semana amortiza completamente el coste operativo del software y añade un flujo positivo neto desde el primer mes.

8 Glosario Técnico y Clínico

EHR (Electronic Health Record): Plataforma clínica centralizada donde se registran historiales, recetas y horarios de los médicos.

WebRTC: Protocolo en tiempo real de baja latencia para transmisión directa de audio sin depender de líneas telefónicas tradicionales.

VAD (Voice Activity Detection): Módulo que detecta milimétricamente cuándo el usuario habla y cuándo guarda silencio, posibilitando cortes.

STT (Speech-to-Text): Motor que convierte ondas acústicas en texto analizable por el modelo de lenguaje de forma ultrarrápida.

TTS (Text-to-Speech): Generador neural de voz artificial con modulación de pausas, respiración e inflexiones conversacionales.

Copago (Copay): Tarifa regulada que el paciente abona directamente en el centro médico según su contrato de aseguradora.

9 Guía de Ejecución Rápida (Quickstart)

El repositorio incluye automatizaciones completas para entorno local en Windows/macOS:

Paso 1: Levantar el Backend Clínico (EHR API) `.\start_server.bat`

Inicia FastAPI en `http://127.0.0.1:8000` con documentación Swagger disponible en `/docs`.

Paso 2: Conectar el Agente de Voz (Clara) `.\start_voice_agent.bat`

Se vincula a LiveKit Cloud y queda en estado de escucha activa para atender salas de voz entrantes o salientes.

Paso 3: Abrir la Torre de Control (Dashboard) `.\start_dashboard.bat`

Abre `http://localhost:3000`. Pulsa **Start Test Call** para interactuar con Clara o simula cancelaciones en tiempo real.

Paso Opcional: Modo Consola (Terminal Textual) `python simulated_agent.py`

Ejecuta toda la lógica de reserva de turno y rescate de citas simulado en terminal sin necesidad de hardware de audio.

ProsperAI Clinic Systems • Documentación de referencia para despliegue clínico y comités directivos.